

语义计算工具库

招标文件技术要求

语义计算工具库需提供的功能包括 语步识别工具、自动分类工具、关键词识别工具、研究问题识别工具、引用句识别工具、概念定义识别工具、命名实体识别工具、深度聚类工具、聚类标签生成工具、结构化自动综述工具。

序号	功能模块	功能项	招标技术要求
1	语义计算工具库	语步识别工具	需实现从科技文献文本中自动标注出表示研究背景、研究目的、研究方法、研究结果、研究结论的句子。支持中文摘要语步识别、英文摘要语步识别、中文基金项目语步识别等功能，针对不同的文献类型可选用不同的功能实现语步识别效果。
		自动分类工具	支持按照中图分类法，根据输入的科技文献文本片段，将科技文献细分到中图分类法不少于 2105 个科学技术类目当中。支持对交叉学科文献给出若干备选分类号，供用户自行选择。支持中文科技文献分类、英文科技文献分类、专业领域科技文献分类等功能。
		关键词识别工具	支持从输入的科技文献文本片段中自动抽取若干个文献关键词。支持中文科技文献关键词识别、英文科技文献关键词识别等功能。
		研究问题识别工具	支持从输入的科技文献文本片段中，自动识别表达文献研究问题的句子以及该句中表达研究问题的短语。
		引用句识别工具	支持从科技文献全文中，自动识别出标注引用的句子，支持揭示出引用句子的引用情感与引用意图。
		概念定义识别工具	支持从科技文献全文片段中，自动识别出描述定义概念的句子，支持揭示出该句中被定义的概念词。
		命名实体识别工具	支持从科技文献文本片段中，自动识别出通用与专业领域的实体词或短语。支持中英文通用领域命名实体识别工具、中英文通用科研实体识别工具、专业领域科研实体识别工具、实体关系识别工具等工具。
		深度聚类工具	支持将用户上传的多篇科技文献文本，自动根据文本中的句子特征进行聚合，形成若干类簇。

		聚类标签生成工具	支持在深度聚类工具的基础上，自动生成各类簇的类簇标签。支持用简短、具有概括性的词或短语揭示每个类簇中的主要内容。
		结构化自动综述工具	支持将科技文献检索结果集或某一科技文献集，自动按照研究问题-研究方法-研究进展的三层树形结构综合分析，支持揭示文献集的研究脉络与研究骨架。

功能需求分析

语义计算工具库

语义计算工具库需支持语步识别工具、自动分类工具、关键词识别工具、研究问题识别工具、引用句识别工具、概念定义识别工具、命名实体识别工具、深度聚类工具、聚类标签生成工具、结构化自动综述工具。

语步识别工具

语步识别工具需支持从科技文献文本中自动标注出表示研究背景、研究目的、研究方法、研究结果、研究结论的句子。语步识别工具包括了中文摘要语步识别、英文摘要语步识别与中文基金项目语步识别三种功能，针对不同的文献类型可选用不同的功能实现语步识别效果。该工具通过句法、语义及位置特征识别句子功能，有助于自动生成科研摘要结构分析与写作风格辅助。

自动分类工具

自动分类工具需支持按照中图分类法，根据输入的科技文献文本片段，将科技文献细分到中图分类法 2105 个科学技术类目当中。若文献存在学科交叉的情况，自动分类工具也会给出若干备选分类号，供用户自行选择。自动分类工具包括了中文科技文献分类、英文科技

文献分类与专业领域科技文献分类。该工具可实现科技文献的精细化学科归属与多标签分类，支持自动推荐候选分类号，辅助科研文献管理与主题聚合。

关键词识别工具

关键词识别工具旨在从海量的科技文献文本片段中实现关键词的自动化、精准化抽取。这项工具能够深入理解文献的核心内容和主题，并将这些信息浓缩为若干个具有高度概括性的关键词。关键词识别工具包括中文科技文献关键词识别与英文科技文献关键词识别两个功能。具体来说，该工具运用了先进的自然语言处理技术，并结合了深度学习算法。它能够自动进行语义分析，从而精准识别出文本中的关键术语、概念和主题词。对于中文文献，工具能够有效处理分词、词性标注等基础性难题；对于英文文献，则能准确识别各类专业术语和缩写。

研究问题句识别工具

研究问题句识别工具旨在智能化分析科技文献，自动筛选并高亮表达研究问题的核心句子，并通过深度语义理解，精准锁定并提取出承载研究问题关键信息的短语。基于这些识别结果，工具可从问题视角出发，自动归纳和聚合核心关键词，帮助研究者快速把握文献焦点，显著提升科研文献的分析与信息检索效率。

引用句识别工具

引用句识别工具需支持从科技文献全文中，自动识别出标注引用的句子，并揭示出引用句子的引用情感与引用意图。引用情感是指科

技文献作者对引用文献价值的态度，包含“支持”、“中立”、“有局限性”三类。引用意图是指文献作者引用文献的目的，包括“用于背景介绍”、“用于引入研究方法”、“用于结果比较”等。

概念定义识别工具

概念定义识别工具能够自动解析科技文献全文内容，精准定位那些包含概念定义表述的关键句子，并进一步提取出这些句子中作为被定义对象的核心概念术语。该工具通过自然语言处理技术识别定义句式的语言模式，如“被称为”“是指”“定义为”等标志性表达，从而帮助研究人员快速把握文献中的关键概念及其内涵，显著提升文献阅读和知识提取的效率，特别适用于科研综述、知识图谱本体构建等应用场景。

命名实体识别工具

命名实体识别工具需支持从科技文献文本片段中，自动识别出通用与专业领域的实体词或短语。命名实体识别工具包括：中英文通用领域命名实体识别工具、中英文通用科研实体识别工具、专业领域科研实体识别工具、实体关系识别工具。其中中英文通用领域命名实体识别工具能识别文本中常见的人名地名等；通用科研实体工具则专注于识别**生物**、**计算机**等科学概念；专业领域科研实体识别工具则深度挖掘特定学科的专业术语，例如识别特定的疾病或化学物质；实体关系识别工具更进一步，在识别出实体后，自动分析并确定它们之间存在的如“治疗”或“抑制”等复杂的语义关系，从而构建出结构化的知识网络。

深度聚类工具

深度聚类工具需支持将用户上传的多篇科技文献文本，自动根据文本中的句子特征进行聚合，形成若干类簇。该工具基于文本语义向量与句子特征对多篇文献进行聚类，自动归纳相似主题或研究方向，揭示文献集合的潜在研究结构与趋势分布。

聚类标签生成工具

聚类标签生成工具在深度聚类技术基础上，能智能分析并挖掘每个簇内数据的核心特征，自动提炼出简短且具有高度概括性的词或短语作为类簇标签，从而揭示各类簇的核心内容。这一功能有效解决了传统聚类结果难以解读的问题，尤其在科研领域，可实现对海量文献的无监督学习，自动归纳出研究主题与发展脉络。最终结合可视化技术，该工具能直观展示学科热点、知识结构与前沿动态，为科研人员高效探索和分析文献提供有力支持。

结构化自动综述工具

结构化自动综述工具通过智能算法，将海量的科技文献或指定文献集，按照“研究问题-研究方法-研究进展”这一核心逻辑进行深度剖析与重组。该工具首先运用自然语言处理技术，精准识别并提炼出每篇文献所探讨的核心研究问题，将它们作为树形结构的顶层节点。接着，它会自动深入分析文本内容，归纳出为解决各个研究问题所采用的具体研究方法，构成第二层级的枝干。最后，工具会进一步整合与分析文献中的实验结果、结论与发现，将这些提炼为具体的研究进展，挂载到相应的方法节点之下，形成完整的第三层级。通过构建这

样一个层次分明、逻辑清晰的知识树，该工具能够自动化地揭示出整个研究领域的宏观脉络与微观骨架，帮助科研人员快速掌握某一方向的重点、方法论演进及前沿动态。

语义计算工具库

系统概述

语义计算工具库是面向科技信息全生命周期的核心能力组件，聚焦“从文本到知识”的智能转化，通过对中文与英文科技文献的多层语义理解与结构化加工，将海量、异构、非结构化的科研文本快速转化为可计算、可检索、可融合的知识资产。该工具库以政府、高校、科研机构、企业与智库等用户的实际应用为导向，服务基础研究、应用基础研究及未来产业群落的情报分析、创新洞察与辅助决策，构建标准化、可扩展的语义处理底座，为科技知识图谱、科技指数计算、智慧搜索、专题综述、成果评价、趋势研判等上层业务提供稳定、高质量的数据与知识供给。

工具库以多粒度语义计算为主线，覆盖句子—段落—文献—文献集的层层递进处理：一方面从微观层面识别文献的语篇结构、研究对象与问题、关键概念与实体、引用意图与情感等语义要素，精确感知学术文本的表达逻辑与证据链；另一方面在中观层面完成主题归类、关键词抽取、类簇聚合与标签生成，提炼学科主题与研究脉络；在宏观层面形成结构化自动综述与跨文献的知识骨架，支持对研究进展的系统性刻画与趋势分析。通过这一“微观理解—中观组织—宏观综合”的协同机制，工具库实现了对科技文本的全维度语义建模与业务化输

出。

为保障应用落地与持续迭代，语义计算工具库在模型与工程层面坚持“知识增强、可解释、可复用”的设计原则：

(1) 知识增强：融合中图分类法、领域本体与术语库等知识资源，支持通用与专业场景的精细化识别与分类，并对交叉学科提供多候选分类结果以提升适配性。

(2) 可解释：输出结构化标注与置信度评估，保留证据句与来源信息，支持人机协同校正与质量审计，便于在政策研究、评估与研判场景中可信使用。

(3) 可复用：提供标准化 API/SDK 与可插拔工具链，支持云端服务与本地化部署，满足批量任务处理、在线交互标注与增量更新等多种使用模式。

工具库的服务目标在于以统一标准与高性能能力，解决科技文献处理的常见痛点：手工标注成本高、跨语言与跨领域迁移难、语义结果不可用或不可解释、从文献到洞见链路长。通过对语篇识别、分类归纳、关键词与实体抽取、引用语义分析、深度聚类与综述生成等能力的集成化供给，语义计算工具库让用户能够更快地理解研究背景与目的，更准确地把握方法与结果，更系统地复盘研究进展与趋势，并以结构化数据驱动上层的可视化、分析与决策。

总体而言，语义计算工具库的作用与目标是：

(1) 将非结构化科技文本转化为可计算的语义资产，缩短从信息到知识、从知识到洞见的路径；

(2)通过标准化接口与工程化能力,支撑平台化集成与规模化处理,成为深度挖掘算法体系中的通用语义底座;

(3) 面向决策、创新与智库三大场景, 提供可视、可查、可挖掘、可分析的语义结果与知识结构, 显著提升科技信息的组织效率与应用价值。

借助该工具库, 用户能够在海量文献中快速提炼关键问题、方法与结论, 自动形成主题类簇与结构化综述, 完善知识图谱并驱动多维可视化分析与预测推演, 从而为科技管理、科研创新与战略研判提供坚实的语义计算支撑。




图 语义计算工具库业务流程图

语义计算工具库的业务流程分为(1) 文本输入处理、(2) 特征识别标注、(3) 语义分析抽取、(4) 深度计算聚合、(5) 综合输出展示 5 个阶段。

(1) 文本输入处理

文本输入处理是语义计算工具库的起始阶段,主要负责接收和预处理各类科技文献文本数据。该阶段支持多种格式的文献输入,包括PDF、Word、纯文本等常见文档格式,并能够处理中英文双语文献。系统会对输入的文献进行智能识别,自动提取文献的标题、摘要、正文、参考文献等结构化信息。同时,该阶段还会进行文本清洗工作,去除无关符号、统一编码格式、修正乱码问题,并对文本进行分段、分句等基础处理。此外,系统还会识别文献的元数据信息,如作者、发表时间、期刊来源等,为后续的深度分析提供完整的文献背景信息。通过这一阶段的处理,原始的非结构化文献数据被转化为标准化、结构化的文本数据,为后续的特征识别和语义分析奠定坚实基础。

(2) 特征识别标注

特征识别标注阶段是对预处理后的文本进行深度的语言学和语义学分析。该阶段运用先进的自然语言处理技术,对文本中的各类语言特征进行自动识别和标注。语步识别工具能够识别文献中表达研究背景、研究目的、研究方法、研究结果和研究结论的句子,帮助理解文献的逻辑结构。命名实体识别工具则可以从文本中提取出人名、机构名、地名、专业术语等实体信息,并识别这些实体之间的关系。引用句识别工具能够定位文献中的引用语句,并分析引用的情感倾向(正面、负面或中立)和引用意图(支持、对比或批评)。概念定义识别工具则专门识别文献中对专业概念进行定义和解释的句子。通过这

些工具的协同工作，系统能够全面标注文本的语言特征，为下一步的语义抽取提供丰富的标注信息。

(3) 语义分析抽取

语义分析抽取阶段在特征识别的基础上，进一步挖掘文本的深层语义信息和知识内容。自动分类工具依据中国图书馆分类法(中图法)，将科技文献精确分类到上千个科学技术类目中，对于跨学科文献还能提供多个备选分类供用户选择。关键词识别工具通过语义分析算法，从文本中自动提取最能代表文献核心内容的关键词和关键短语，这些关键词不仅包括作者标注的关键词，还包括系统从全文中挖掘出的隐含关键概念。研究问题识别工具则专注于识别文献试图解决的核心科学问题，准确定位表达研究问题的句子和短语，帮助读者快速把握文献的研究重点。这一阶段的工具能够处理中英文文献，并针对不同专业领域提供定制化的分析模型，确保语义抽取的准确性和专业性，为研究人员提供精准的文献语义分析。

(4) 深度计算聚合

深度计算聚合阶段是对多篇文献进行批量处理和综合分析的关键环节。当用户输入多篇相关文献或一个文献检索结果集时，深度聚类工具会运用先进的机器学习算法，基于文本的语义特征自动将文献聚合成若干个主题类簇。这种聚类不是简单的关键词匹配，而是基于深层语义理解，能够发现文献之间潜在的主题关联和研究相似性。聚

类标签生成工具则会为每个类簇自动生成简洁、准确的标签，用概括性的词语或短语揭示该类簇的核心主题和研究方向。系统还会分析每个类簇的特征进行文本聚合分析，包括该主题下的文献数量、研究趋势、主要研究机构和学者等统计信息。通过这一阶段的深度计算，大量分散的文献被有序地组织起来，研究人员可以快速了解某一领域的研究全貌和主要研究方向，大大提高文献阅读和知识发现的效率。

(5) 综合输出展示

综合输出展示阶段是语义计算工具库的最终呈现环节，将前期所有分析结果进行整合和可视化展示。结构化自动综述工具是这一阶段的核心功能，它能够将文献集按照"研究问题-研究方法-研究进展"的三层树形结构进行自动组织和综合分析。第一层展示该领域的主要研究问题，第二层归纳解决这些问题所采用的主要研究方法，第三层梳理各研究方向的最新进展和研究成果。系统自动生成的综述不是简单的文献罗列，而是经过深度语义分析后的结构化知识呈现，能够清晰地生成研究脉络揭示研究领域的知识脉络和研究骨架。输出形式包括可交互的知识图谱、结构化的文本综述、统计图表等多种形式，用户可以根据需要选择不同的展示方式。这种自动化的综述生成大大减轻了研究人员的文献综述工作负担，帮助他们快速把握研究前沿，发现研究空白和创新点。

3.2.2.3 功能架构



图 语义计算工具库功能架构图

语义计算工具库主要包括文本识别工具和文献分析工具两大模块。

(1) 文本识别工具的子功能包括：语步识别工具、自动分类工具、关键词识别工具、研究问题识别工具、引用句识别工具、概念定义识别工具、命名实体识别工具。

(2) 文献分析工具的子功能包括：深度聚类工具、聚类标签生成工具、结构化自动综述工具。

3.2.2.4 具体功能

语义计算工具库是科技情报语义分析与智能信息处理体系的重要组成部分，旨在为多源、多语言、多领域的科技文献与科研文本提供高精度的语言理解与知识抽取能力。通过集成多类型自然语言处理模型与语义分析算法，该工具库能够从文献中自动识别结构化要素、

归类主题、提取关键知识点并生成多层次综述结构，全面支撑科技情报的深度挖掘与智能分析。

语义计算工具库面向科研管理、科技创新、前沿趋势分析、政策评估等多场景，提供从文本读取、语义解析到知识结构化的全链路支撑服务。它既是上层专题分析、决策支持等功能模块的语义底座，也是后续模型拓展与算法创新的核心依托，具备接口标准化、组件可复用、跨语言适配能力。

用户群体可以通过 AI 引擎客户端、AI 引擎网站或例子程序等方式将待处理的文献上传到科技情报语义计算工具库，根据用户需求，该工具库依托语步识别模型、文献分类模型，通过 GPU、超算集群等高性能计算层实现多项任务：

语义计算工具库的功能包括：

（1）语步识别工具：自动识别并标注科研文献中研究背景、研究目的、研究方法、研究结果和研究结论等语步类别，将非结构化文本转化为结构化信息。

（2）自动分类工具：基于中图分类法实现多层级精细化分类，支持中文、英文及专业领域科技文献分类，兼顾交叉学科多标签推荐。

（3）关键词识别工具：自动抽取文献中反映主题的关键短语或术语，支持中文和英文科技文献处理。

（4）研究问题识别工具：定位和抽取文献中的核心研究问题句及其关键短语，支撑热点发现与科研趋势分析。

（5）引用句识别工具：识别文献中引用句并分析引用情感（支

持、中立、有限制)与引用意图(背景介绍、方法引入、结果比较)。

(6) 概念定义识别工具: 自动识别并提取文献中定义领域概念的句子及被定义词项, 支持领域知识体系构建。

(7) 命名实体识别工具: 识别文本中的多类型实体(人名、机构名、研究方法、数据资源等)及其关系, 支持通用与专业领域的细粒度处理。

(8) 深度聚类工具: 基于句子级语义分析自动聚合同主题文献, 形成多个主题簇, 支持趋势与热点分析。

(9) 聚类标签生成工具: 为聚类结果生成简洁、具代表性的主题标签, 提高聚类成果的可读性与应用效率。

(10) 结构化自动综述工具: 将文献集自动组织为“研究问题—研究方法—研究进展”的三层树形结构, 揭示领域研究脉络与知识骨架, 并支持溯源询证。

3.2.2.4.1 语步识别工具

语步识别工具用于从科技文献中自动识别并标注句子的语步类别, 包括研究背景、研究目的、研究方法、研究结果和研究结论, 从而将非结构化文本转化为结构化信息。该工具适配多类型科技文献和不同语言场景, 当前包含中文摘要语步识别、英文摘要语步识别和中文基金项目语步识别三个功能模块。

工具基于改进的 Masked Sentence Model (MSM) 算法, 将句子原始内容特征与屏蔽后的上下文特征进行融合编码, 并结合 BERT 预训练模型进行微调, 从而显著提升语步识别的准确率与稳定性。模型

在训练阶段采用类别均衡的语步样本集，以保证不同语步识别的一致性与泛化能力。在多语种、多类型文献处理场景中，工具可灵活配置不同识别模块，以适配不同语言及文献格式，实现从文本输入到语步标注输出的高效全流程处理。

用户可通过平台界面或 API 接口提交文献摘要，系统自动分析每个句子的语义特征与上下文关系，输出带有语步标签的注释结果，支持批量处理与单篇分析，为科研人员、情报分析师及项目管理人员提供精准、高效的文本要点提取能力。

3.2.2.4.1.1 中文摘要语步识别

面向国内科技期刊、学术会议等中文文献摘要场景，结合中文学术写作的结构特征与语言习惯，优化语步识别在复杂术语、多样句式下的解析能力。

(1) 算法阐述

模块利用篇章结构分析结合句间逻辑关系，提取摘要中的不同语步（如研究背景、目的、方法、结果、结论），并通过上下文关联建模确保识别的准确性和一致性。输出的语步信息可用于自动生成摘要结构化索引，帮助科研人员快速抽取关键信息并提升情报分析效率。

(2) 算法输入与输出

输入：中文科技文献摘要文本。

输出：结构化语步识别结果，含语步类别、句子位置、原文片段及置信度评分。

(3) 调用方式

支持通过科研情报分析平台界面上传文件或调用 Restful API/SDK 接口进行批量识别,输出可为 JSON、CSV 或数据库格式,并可与文献管理或索引系统对接。

3.2.2.4.1.2 英文摘要语步识别

针对国际科技文献(包括 SCI、EI 期刊及国际会议论文),该模块结合英文写作的语步分布规律与逻辑衔接特征,实现跨学科领域内的精确标注。

(1) 算法阐述

通过多语境特征建模,本模块在生物医药、工程技术、计算机科学等英文科研文本中保持高识别率,自动提取摘要中的背景、目的、方法、结果及结论等语步信息。该功能可有效支持国际合作、英文文献调研及跨语言信息处理需求。

(2) 算法输入与输出

输入:英文科技论文摘要(SCI/EI 期刊论文及国际会议论文文本)。

输出:结构化的语步识别结果,包含语步类型、句子位置、上下文信息及置信度。

(3) 调用方式

支持通过国际科技文献分析平台或跨语言信息处理系统调用,API 可批量处理英文摘要并输出 JSON/CSV 格式结果,支持与跨语言检索系统集成。

3.2.2.4.1.3 中文基金项目语步识别

该算法面向科研立项书、基金申请书及科研管理相关文件,专注

于识别项目的立项依据、研究目标、技术实施方案、预期成果和应用价值等关键语步。

(1) 算法阐述

模块在训练过程中分析基金申请文档的篇章逻辑与正式书写规范，通过要素分类标注体系将核心内容提取并结构化存储。识别结果可为科研管理部门提供项目要素抽取、分类分析及绩效评估的数据支撑，有助于提升科研项目管理的信息化与自动化水平。

(2) 算法输入与输出

输入：中文基金申请书、立项书、科研项目管理文件文本。

输出：项目语步识别结果，包括类别标签、文本位置、原文片段及置信度评分。

(3) 调用方式

可在科研管理信息系统中调用，支持批量处理与实时识别，API/SDK 可将结果直接写入项目数据库并用于自动化绩效评估模块。

3.2.2.4.2 自动分类工具

自动分类工具基于中图分类法，能够将输入的科技文献文本片段自动归入 2105 个科学技术类目，并在存在学科交叉时给出若干备选分类号，供用户人工确认。该工具适用于中文科技文献、英文科技文献及专业领域科技文献的分类处理，可满足跨语言与多领域文献的智能标注需求。

工具采用多层级分类模型架构，结合 BERT 等深度语言模型进行文本语义特征提取，并针对特定领域调整模型参数与训练集配置，从

而提升分类的准确性和稳定性。用户可通过科技情报语义计算平台或 API 接口提交文本数据，系统自动完成分类分析并返回中图分类号列表，实现单篇或批量分类结果的快速生成，辅助文献筛选与领域情报分析。

3.2.2.4.2.1 中文科技文献分类

面向中文期刊论文、会议文稿、科技报告及政策文件等多类型文献，结合中文分词、领域术语识别及篇章结构分析，实现高精度的中图分类号预测。

(1) 算法阐述

该算法面向中文期刊论文、会议文稿、科技报告及政策文件等多类型文献，结合中文分词技术、领域术语自动识别和篇章结构分析，实现高精度的中图分类号预测。在模型训练过程中，使用大规模、标注准确的中文科技文献摘要作为训练语料，充分适配中文语法结构与语义特征，提升分类结果的一致性与准确度。该模块支持批量处理本地或在线抓取的中文文献，快速实现归类与按领域筛选，适用于情报分析、专题研究及信息检索等任务。

(2) 算法输入与输出

输入：中文科技文献文本（期刊论文、会议文稿、报告、政策文件）、标准中图分类号标注数据。

输出：每篇文献的中图分类号预测结果、分类置信度、领域标签及归类统计表。

(3) 调用方式

支持通过批量文件上传、数据库接入或 Restful API 方式调用，接口可返回 JSON、CSV 格式结果，便于与情报管理系统、检索平台对接。

3.2.2.4.2.2 英文科技文献分类

用于处理国际期刊论文（如 SCI、EI）、英文会议论文及科研项目英文摘要，借助英文语法解析、多领域术语向量建模及跨学科语义匹配技术，实现对英文文献的中图分类号自动标注。

(1) 算法阐述

该算法支持处理国际期刊论文（如 SCI、EI）、英文会议论文及科研项目英文摘要，利用英文语法解析、多领域术语向量化建模和跨学科语义匹配，实现对英文文献的中图分类号自动标注。模块在构建过程中引入多领域英文语料，并结合中图分类法的类目映射策略，确保分类结果与中文类目体系保持一致，实现中英文文献的统一管理与跨语言情报分析，尤其适用于国际合作机构、跨国研究团队的文献整合与分类需求。

(2) 算法输入与输出

输入：英文科技文献文本（期刊论文、会议文稿、科研项目摘要）、中图分类标准及映射规则。

输出：中图分类号预测结果、跨语言类目映射表、领域标签及文献分布分析报告。

(3) 调用方式

支持通过批量数据接入、文件上传及 Restful API 调用，结果可

输出为 JSON、XML、CSV 格式，并可跨语言情报分析平台对接。

3.2.2.4.2.3 专业领域科技文献分类

针对医学、材料科学、能源技术等高专业化领域，结合特定领域的语料和分类规则进行优化，实现细粒度的多层级分类。

(1) 算法阐述

以医学领域为例，模块采用两层分类模型：第一层预测所属医学二级类目（如 R1 - R9），第二层在大类内部进一步细分至具体的医学三级类目（R11 - R99），总计完成 112 个细分类别的预测。训练与测试阶段均采用人工审核的高质量样本，确保领域分类精准性。同时，该框架可根据用户业务需求扩展至其他专业领域，实现分类体系的定制化。

(2) 算法输入与输出

输入：领域专业科技文献数据、领域分类规则及人工标注训练数据。

输出：多层级领域分类结果、分类置信度、领域标签及数据分布报告。

(3) 调用方式

支持在领域情报平台、科研管理系统中调用，提供 API、SDK 接口，可实时查询或批量分类结果，并可跨学科知识库及可视化分析系统对接。

3.2.2.4.3 关键词识别工具

关键词识别工具从输入的科技文献文本片段中自动抽取文献关

关键词，即反映文献主题的重要短语或术语。这一功能在信息检索、文本摘要生成、文献分类、意见挖掘及科学情报分析中具有基础性作用。系统支持中文科技文献关键词识别与英文科技文献关键词识别两种处理模式，可根据文献语言自动选择对应模块，确保抽取结果的准确性与专业性。**关键词识别工具**功能截图如下（最终页面以采购人需求确认为准）。

工具基于 BERT 预训练模型微调，将关键词抽取任务定义为字符/词级的序列标注问题，并采用 BIO 标记法识别关键词边界，从而提升在多语言、多领域科技文献中的抽取精度与稳定性，进而提升情报分析效率。用户可通过科技情报语义计算工具或关键词识别 API 接口，将待处理文本输入后，通过调用分类模型接口从文本中抽取重要的主题短语，作为该文献的关键词。

3.2.2.4.3.1 中文科技文献关键词识别

面向来自期刊论文、学术会议、科技报告等中文文献摘要的关键词抽取任务，结合中文分词优化与字符级序列标注策略，有效应对中文关键词边界识别的难点，确保专业术语和复合词组的完整抽取。

(1) 算法阐述

算法支持多领域中文科技语料（如医学、工程、材料科学等），在领域术语提取上具备较高精度。通过引入领域词典和动态词权计算机制，提升了关键词在不同文本结构中的稳定性与准确性，使其适合本地化情报分析及专题研究任务。

(2) 算法输入与输出

输入：中文科技文献摘要及可选领域术语词典。

输出：结构化关键词列表。

(3) 调用方式

支持通过文献管理平台上传文件或调用 Restful API / SDK 进行批量处理，输出可为 JSON、CSV 格式，并可与情报分析系统、搜索引擎对接。

3.2.2.4.3.2 英文科技文献关键词识别

针对英文科研文献（包括 SCI/EI 期刊、国际会议论文等）的关键词抽取任务，利用英文单词级别序列标注和跨领域术语识别技术，实现对英文摘要主题短语的精准抽取。

(1) 算法阐述

模块同时优化了学科专属术语和跨领域词汇的识别能力，并在分类标签上实现与中图法类目或其他科研分类体系的兼容，使抽取的关键词能直接用于国际合作、跨语言科研分析与关键词管理。算法可根据目标领域调整词汇权重与短语边界规则，以提升跨领域检索与分析的效果。

(2) 算法输入与输出

输入：英文科研文献摘要、领域术语库及分类标准映射表。

输出：结构化关键词或主题短语列表。

(3) 调用方式

支持文献数据平台、科研情报分析系统通过 Restful API 或 SDK 调用，可定制输出格式（JSON、XML、CSV），并支持关键词与分类

标签的统一管理接口。

3.2.2.4.4 研究问题识别工具

研究问题识别工具从输入的科技文献文本片段中，自动抽取表达文献研究问题的句子以及该句中明确表述研究问题的短语，实现对科研文献核心研究议题的精准定位。该工具适用于各学科领域的科技文献，包括论文摘要、项目申请书及技术报告等，能够直接输出结构化的研究问题信息，帮助科研人员快速理解文献的研究意图和核心问题，减少人工筛选的时间与成本。在情报分析场景中，该能力可显著提升前沿热点发现与关键技术识别的效率，并可为科研趋势分析、技术路线规划等提供可靠的数据支撑。

(1) 算法阐述

该算法结合预训练语言模型（BERT）与深度语义理解技术，融合句子级分类与短语级序列标注两种方法，先通过上下文语义编码识别研究问题句，再在句内抽取概述研究范围、目标或假设的关键短语。算法可适用于跨学科领域的科技文献，包括论文摘要、科研项目申请书、技术报告等，并可在情报分析、趋势预测、技术路线规划等应用场景中发挥显著作用。

(2) 算法输入与输出

输入：科技文献文本片段、文本格式要求。

输出：研究问题句列表、对应的研究问题短语列表、结构化研究问题数据、研究问题统计摘要。

(3) 调用方式

研究问题识别工具支持通过 Restful API 或 SDK 调用，调用时用户可将待处理的科技文献文本片段作为参数输入，并指定输出格式。系统会自动执行语义分析与信息抽取，并返回研究问题句及短语的结构化结果，支持与情报分析平台或科研管理系统集成，实现自动化批量处理与在线检索。

3.2.2.4.5 引用句识别工具

引用句识别工具旨在从科技文献全文中自动识别引用句，并判断其引用情感与引用意图。引用情感反映作者对被引文献价值的态度，分为支持、中立、有局限性三类；引用意图表示引用的目的，分为用于背景介绍、用于引入研究方法、用于结果比较三类。

工具基于 BERT 深度语言模型，结合大规模引文语料的特征训练，实现多领域、多学科的高精度引用句判别与属性标注。用户可通过科技情报语义计算平台或 API 接口提交文献文本，系统在返回引用句结果的同时给出情感与意图分析，支持批量或单篇处理。该工具可为被引文献影响力评估、科研成果价值分析及学术传播模式研究提供重要数据支撑。

3.2.2.4.5.1 引用情感识别

引用情感识别功能用于判断科技文献中被引文献在原文作者眼中的价值倾向，以“支持”、“中立”和“有局限性”三种类别体现引用的态度。这一功能能够揭示文献在学术交流中的正向肯定、中性陈述或批判性评价，对于评估科研成果质量与影响力具有重要意义。

(1) 算法阐述

模块以 PubMed Central 生物医学全文数据 为核心语料来源，覆盖 1781 - 2021 年间的 216 万余篇文章，重点集中在 2006 - 2021 年的期刊出版物。通过规则抽取引用句并匹配相应引文信息，构建约 1.10 亿条引用句记录 和 8250 万条引文信息记录 的双数据库。在模型训练阶段，算法融合引用句的语义特征与上下文信息进行深度建模，通过多分类情感识别模型，精确判定被引文献在原文中的引用态度类型。

(2) 算法输入与输出

输入：科技文献全文数据、引用句及其上下文、引文元数据。

输出：带有情感标签（支持、中立、有局限性）的引用识别结果清单，附上下文片段与置信度。

(3) 调用方式

支持通过 API 或 SDK 按文献批量提交文本，系统自动完成引用句抽取与情感分类，并返回结构化 JSON/CSV 格式结果；可与文献评估平台、学术检索系统集成实时展示。

3.2.2.4.5.2 引用意图识别

引用意图识别功能用于分析文献作者引用他人研究的动机，分为“用于背景介绍”、“用于引入研究方法”和“用于结果比较”三类。该功能可帮助明确被引文献在研究中的作用定位，揭示其承载的知识贡献方式，从而支持科研活动分析与学术网络构建。

(1) 算法阐述

模块采用 Cohan 发布的 ScisCite 数据集作为训练基础，涵盖医学

与计算机科学领域的引用样例。在数据预处理阶段，移除重复句、乱码及空缺数据，构建包含 4,787 条背景引用句、2,276 条方法引用句和 1,104 条结果比较引用句 的高质量训练集。模型在训练中融合引用句内部语义与上下文关系，并结合 主题一致性分析 方法，精准预测引用目的类别。

(2) 算法输入与输出

输入：引用句文本与上下文、引文元数据、预处理后的训练集。

输出：引用意图标签及对应引用句、上下文片段、置信度评分。

(3) 调用方式

支持通过 API 或 SDK 按领域、时间范围导入数据，自动完成引用意图分类计算；可与科研分析平台、学术图谱系统直接对接，提供在线检索与批量分析服务。

3.2.2.4.6 概念定义句识别工具

概念定义句识别工具从科技文献全文片段中自动识别描述定义某个概念的句子，并准确提取该句中被定义的概念词。该功能可在大规模文献集分析中，快速定位领域术语的定义位置，帮助研究人员了解特定领域的知识体系构成与概念演化趋势。在科技情报分析、知识库构建以及领域术语标准化等场景中，该工具能够高效提供结构化的“概念-定义”数据，为科研与情报工作提供支持。

(1) 算法阐述

该算法将识别任务抽象为二分类问题：判定输入句子是否为“概念定义句”。在模型构建过程中，首先基于来自科技类网站、维基百

科及公开文献语料库的约 8,000 条样本（包含定义句与非定义句）建立训练数据集。随后采用 BERT 预训练语言模型，通过 Fine-Tuning 方法进行语义特征微调，使模型能够精准捕捉定义句的典型语言结构、关键词分布及上下文模式。

在识别阶段，算法会对全文片段进行分句、特征向量化处理，并利用已训练模型预测句子类别；对于被判定为定义句的内容，进一步运用关键词定位与句法分析方法提取句中被定义的概念词。

(2) 算法输入与输出

输入：待处理科技文献全文片段或批量文本数据、可选参数：领域标签、输出格式要求。

输出：概念定义句列表、概念词提取结果、结构化的“概念-定义”映射数据、识别统计分析报告。

(3) 调用方式

概念定义句识别工具支持通过 Restful API、SDK 及批量处理命令行方式调用。用户可提供单篇文献或大规模文献集作为输入，指定领域标签与输出格式。接口会返回识别结果及概念词抽取内容，并可与科技情报分析平台、知识库构建系统、术语标准化工具实现对接，满足在线检索、批量分析及定时任务等应用场景。

3.2.2.4.7 命名实体识别工具

命名实体识别工具旨在从科技文献文本片段中，自动识别通用领域与科研领域的多类型实体词或短语，包括人名、地名、机构名、事件、模型方法、数据资源、仪器设备、理论原理等。同时，工具支持

针对特定专业领域（如医学、化工、物理学）的细粒度实体识别，并可抽取实体之间的关系，为领域科研知识体系建设、情报分析和科研画像库构建提供基础数据。该工具由中英文通用领域命名实体识别、中英文通用科研命名实体识别、专业领域科研命名实体识别以及实体关系识别四个模块组成，适用于多语言、多领域的科技信息处理和知识挖掘。

用户可通过科技情报语义计算工具或命名实体识别 API 接口，将待处理文本输入后，通过调用命名实体识别模型接口从文本中识别通用领域命名实体、通用科研命名实体等。

3.2.2.4.7.1 中英文通用领域命名实体识别

中英文通用领域命名实体识别模块的核心功能包括通用人名识别算法、通用地名识别算法、机构名称识别算法、事件识别算法，以及跨语言实体统一编码与检索算法。

(1) 算法阐述

该算法面向通用科技文献场景，能够自动识别文本中的人名、地名、机构名和事件等通用领域命名实体。识别结果可为跨领域科技信息的整合、检索及索引提供结构化基础，支持情报聚合与学术资源联网。

算法针对中英文文本的不同语言特性，结合词法分析与上下文语义建模，采用深度学习命名实体识别模型，并引入大规模通用领域标注语料进行训练，使模型具备跨语言实体提取能力。通过向量化编码及标签映射机制，确保在中英文混合文本中实现准确识别与一致性输

出。

(2) 算法输入与输出

输入：中英文科技文献文本、通用领域标注语料。

输出：包含实体类别、实体位置、语境片段的识别结果结构化列表。

(3) 调用方式

支持通过批量文件上传、Restful API 或 SDK 调用，结果可导出为 JSON、CSV 或数据库格式，可与文献管理系统、检索平台对接。

3.2.2.4.7.2 中英文通用科研实体识别

中英文通用科研实体识别模块的核心功能包括科研方法识别算法、科研数据资料识别算法、仪器设备识别算法、理论原理识别算法及研究问题识别算法。

(1) 算法阐述

该算法专注于科技研究语料，能自动识别科研类实体，如模型方法、数据资料、仪器设备、理论原理和研究问题，帮助科研人员快速定位核心研究要素。技术实现方面，模块在训练过程中引入多领域科研论文摘要与技术报告数据，结合 BERT 等预训练语言模型进行微调，并采用 BIO 序列标注体系保障实体识别的精准度和上下文一致性。领域自适应机制可在交叉学科语料中优化模型表现。

(2) 算法输入与输出

输入：中英文学术论文摘要、技术报告文本、多领域科研语料及人工标注数据。

输出：结构化的科研实体识别结果，包括实体类型、句子位置、关联上下文及映射标准词表。

(3) 调用方式

可在科研情报分析平台、文献数据库管理系统中通过 API 或 SDK 调用，支持批量处理与实时查询，并可定制输出字段与标签。

3.2.2.4.7.3 专业领域科研实体识别

专业领域科研实体识别模块的核心功能包括医学科研实体识别算法、化工领域实体识别算法、物理学领域实体识别算法及专业本体映射算法。

(1) 算法阐述

该算法针对医学、化工、物理学等专业领域进行优化，能识别医学文献中的药物、疾病、治疗方法，化工文献中的化合物名称，物理学文献中的理论、现象与规律。以物理学为例，算法利用 ScienceWISE 物理学本体构建领域范畴体系（一级 4 类，二级 47 类，如量子力学、核物理学、理论宇宙学等），基于该分类体系和领域预训练模型进行细粒度微调。数据采用 BIO 格式标注（B 表示实体首词，I 表示实体内部词，O 表示非实体词）。物理学训练集约 9 万条，测试集 2000 条，多轮迭代显著提升识别精度。

(2) 算法输入与输出

输入：专业科研文献文本、本体分类体系、领域标注训练数据。

输出：按领域类别细分的实体识别结果，包括实体类型、位置、领域标签及标准知识库映射 ID。

(3) 调用方式

支持通过专业科研情报系统、领域知识库平台调用,提供 API 和 SDK 接口,可按领域标签查询与批量分析,并与知识图谱系统直接对接。

3.2.2.4.7.4 实体关系识别

实体关系识别模块的核心功能包括开放关系抽取算法、句法依存分析算法、实体对语义配对算法及知识网络构建算法。

(1) 算法阐述

该算法采用开放关系抽取技术,识别文本中的实体及其关系类型,实现自动化知识网络构建。可揭示科技文献中不同实体之间的关联模式,如方法与设备的配合、理论与实验结果的依赖等。其在基础实体识别的结果上进行句法依存结构分析,抽取符合语义逻辑的实体对及其关系类型标签,输出可直接进入知识图谱构建、科研信息可视化及跨领域信息融合的结果数据。

(2) 算法输入与输出

输入: 已识别的实体列表、原始句子文本、依存句法分析结果。

输出: 实体关系三元组,附上下文片段与置信度评分。

(3) 调用方式

支持通过知识图谱构建平台或情报分析系统调用,提供批量关系抽取与实时分析功能,API 可输出 JSON、RDF 等格式,方便与可视化前端及推理引擎对接。

3.2.2.4.8 深度聚类工具

深度聚类工具将用户上传的多篇科技文献文本，基于句子级特征进行语义分析和相似度计算，自动将文本聚合形成若干类簇，从而实现文献内容的高效归类与知识结构化。本工具支持不同领域的科技文献处理，可用于主题发现、研究趋势挖掘以及领域热点分析。

(1) 算法阐述

工具首先对文献文本进行标准化处理（包括去重、分句、标点清理、文本洁净度控制），再利用深度语义模型对每个句子编码，生成多维特征向量；随后采用聚类方法（如基于密度、层次或中心点的聚合算法）将文本按语义相似度聚合为不同主题簇。

为了提高聚类的精度与可解释性，算法计划选取 15,920 篇医学领域科技文献摘要作为训练样本，并人工标注约 200 条具有代表性的训练数据，用于确立初始类目标标准与标签体系。在模型评估阶段，构建两类评估集：

1) 线上评估集：贴近真实数据分布，用于验证模型在实际业务场景中的适配度。

2) 随机评估集：基于去重与均匀采样方法构建，用于排查模型在数据分布偏移时的稳定性。

模型训练过程中实施数据清洗、特征一致性检测，并在预测阶段引入“置信度偏差筛选机制”，自动识别并筛选预测误判样本，由人工进行修正，从而形成持续迭代优化的数据闭环。最终算法可输出稳定且高精度的类簇结果，支持主题发现、研究趋势挖掘以及领域热点

分析。

(2) 算法输入与输出

输入：用户上传的多篇科技文献文本、文献元数据、训练样本与人工标注类目标签数据。

输出：聚类结果类簇、类簇特征统计、主题趋势分析结果。

(3) 调用方式

工具支持通过科技情报语义计算平台界面上传文献，或调用标准化 Restful API / SDK 接口进行批量处理。调用时可指定聚类算法类型、类簇数量及输出格式，系统将在后台自动完成数据清洗、特征提取与聚类计算，并返回结构化聚类结果及分析报告。工具可与文献管理平台、科研分析系统等实现无缝对接，支持在线查询与批量主题分析。

3.2.2.4.9 聚类标签生成工具

聚类标签生成工具在深度聚类工具输出的类簇结果基础上，自动为每个类簇生成具有概括性和代表性的标签。标签为简短的词或短语，能够直观揭示类簇的主要内容主题，从而便于用户快速理解每个聚类结果的核心含义。该工具适用于大规模科技文献数据的主题标注，支持跨领域、跨语言的类簇标签生成，为信息检索、情报分析和知识图谱构建提供结构化标签支持。

(1) 算法阐述

工具首先接收深度聚类的类簇短语集合，对其进行文本清洗、词形还原及特征过滤；随后结合词频统计、n-gram 短语组合、共现模式

分析、关联规则挖掘等方法，识别最能体现类簇特征且具有区分度的短语，并选取其中权重最高者作为标签候选。最终通过多策略融合的优化机制，确保输出的标签既简洁、准确，又能有效区分不同类簇。

该工具适用于大规模科技文献、科技情报及跨领域语料的主题标注，支持中英文标签生成，并能与信息检索、情报分析、知识图谱构建等系统联动，提供结构化标签支持。

(2) 算法输入与输出

输入：深度聚类模型输出的类簇短语集合、可选参数（标签长度限制、语言类型、差异度阈值等）。

输出：类簇标签集合、标签生成过程报告、标签差异化优化结果。

(3) 调用方式

聚类标签生成工具支持通过标准化 Restful API、SDK 调用，可按批量模式或单类簇模式运行。用户将待处理的类簇短语集合提交至接口，系统自动返回对应标签集合及分析报告。工具可与深度聚类模块和语义计算平台无缝集成，实现从聚类结果到标签输出的全流程自动化处理，并支持与情报分析系统、知识图谱构建平台对接。

3.2.2.4.10 结构化自动综述工具

结构化自动综述工具对科技文献检索结果集或指定文献集进行自动化综合分析，以研究问题—研究方法—研究进展为三层树形结构展开，直观揭示文献集的研究脉络与知识骨架。系统能够识别并归纳该文献集所涉及的核心研究问题，将相似问题聚合成类簇，并分析不同研究团队在各类问题上采用的研究方法，最终梳理出对应的研究进

展和结论。

(1) 算法阐述

该工具首先通过文本预处理和自然语言理解技术，对文献摘要、正文及参考部分进行语义解析，自动识别并抽取研究问题，并利用相似度计算与语义聚类将相似问题聚合为类簇。随后，针对每个类簇匹配相应的研究方法信息，形成结构化方法节点；最后分析各节点所对应的研究进展及关键结论，并以可视化树形结构呈现整体关联关系。

为保障综述的可反溯性，算法支持“溯源询证”机制，即用户可从综述结构中的任意节点直接定位到原始文献及相关关键句段，实现从宏观综述到微观证据的双向导航。该算法输出的结构化综述可适用于领域文献综述编写、技术趋势分析以及科研证据检索等场景。

(2) 算法输入与输出

输入：文献集、研究主题或关键词、文献元数据。

输出：三层树形结构综述视图（研究问题—研究方法—研究进展）、聚类及类簇归纳结果、结构化文本综述报告、趋势分析与研究热点分布图。

(3) 调用方式

工具支持通过 Restful API、SDK 方式调用，可在浏览器端直接输入研究主题或文献集参数，自动生成结构化综述与可视化结果。可选输出格式包括树形结构平铺视图、折叠视图及结构化文本报告。系统可与科技情报平台、科研管理系统或知识库集成，实现面向科研人员、政策制定者或技术分析师的实时综述生成与证据检索。

